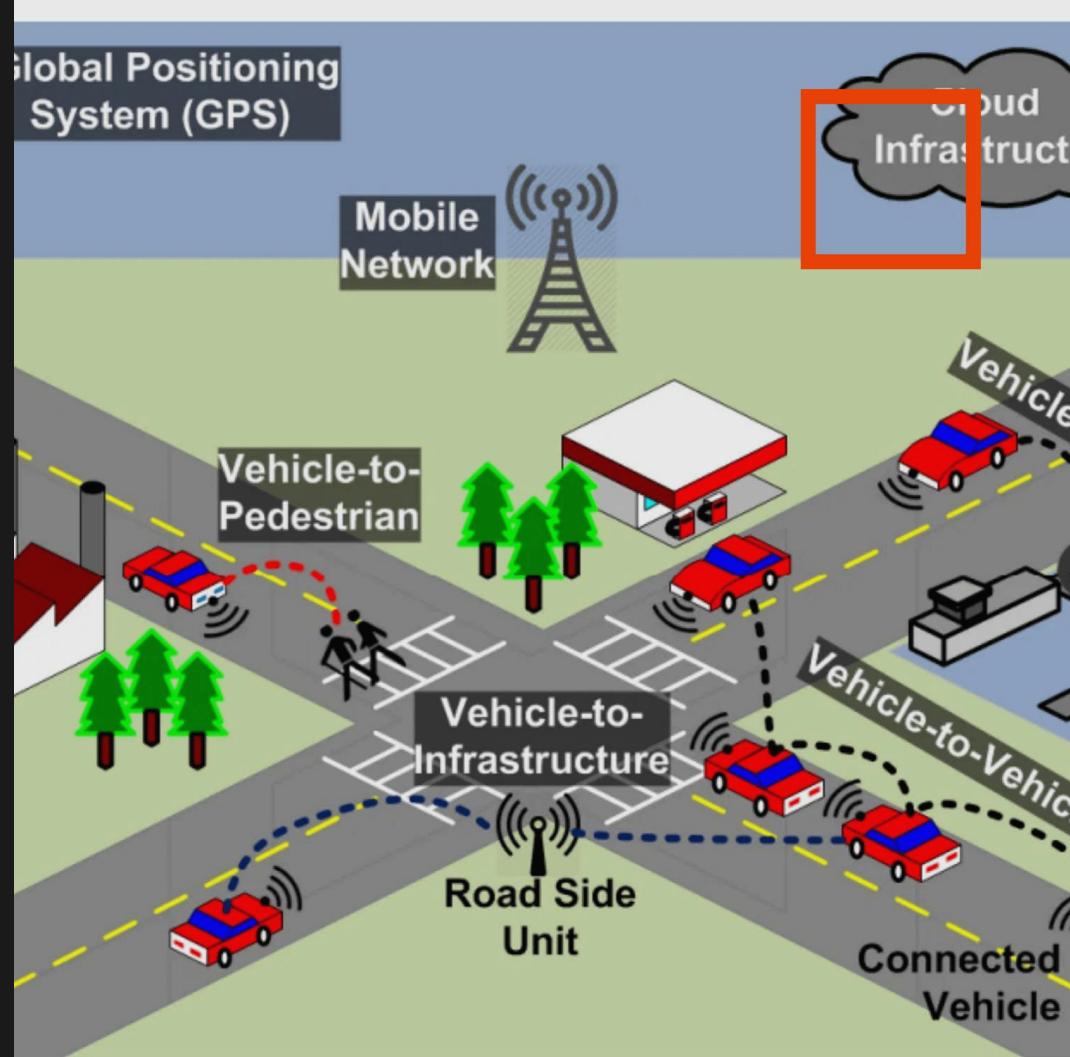


A Sinfonia Integrada

Otimização de Sistemas de Visão
Computacional em Redes Veiculares Através
de Offloading Inteligente e Segurança Baseada
em Identidade

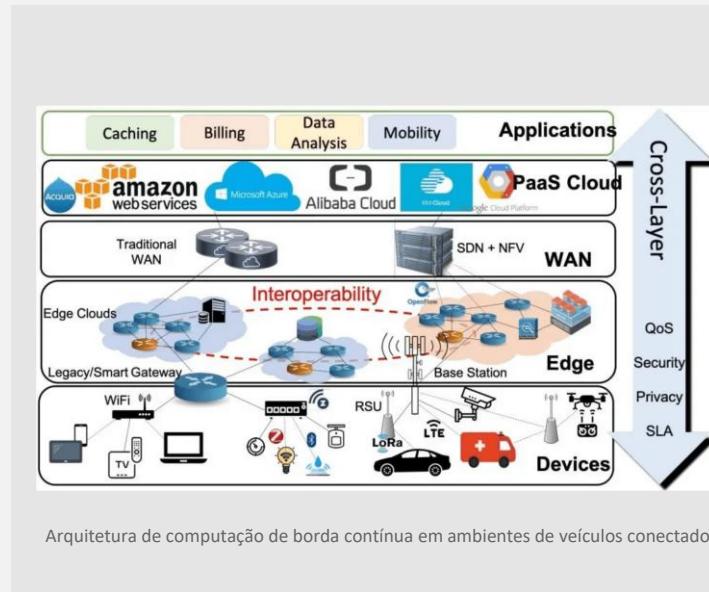


Evolução dos ITS (Sistemas de Transporte Inteligentes)

02

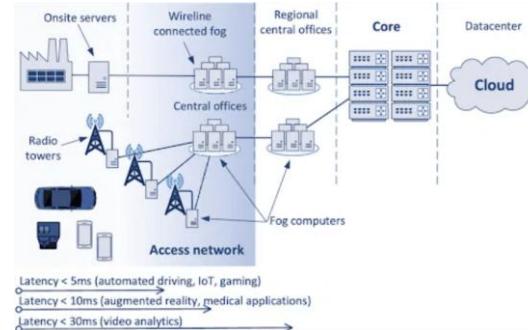
ITS modernos exigem computação de alto desempenho e processamento de dados em tempo real em ambientes veiculares dinâmicos.

- **Mudança Transformativa:**
Integração de sensores embarcados e unidades de processamento melhora segurança e eficiência.
- **Aplicações Críticas:** Habilita Reconhecimento Automático de Placas (ALPR) e Classificação Veicular de Granularidade Fina (FGVC).
- **Fundação VANETs:** Essencial para comunicação Veículo-a-Veículo (V2V) e Veículo-a-Infraestrutura (V2I).
- **Desafios Operacionais:**
Condições de canal variáveis, recursos computacionais limitados e restrições estritas de energia.



Limitações Computacionais e Offloading

Restrições de processamento local impulsionam a adoção de paradigmas de Computação de Borda Veicular (VEC).



VEC Centrado na Borda

Arquiteturas VEC abordam limitações de latência da Nuvem trazendo recursos computacionais para perto dos veículos usando Roadside Units (RSUs) e nós MEC.

Estratégia de Offloading

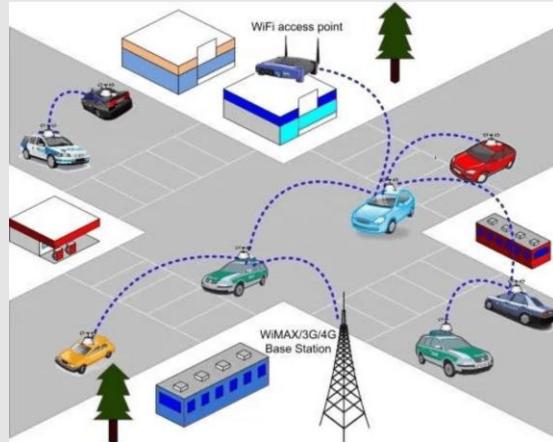
Estratégias eficazes devem equilibrar dinamicamente latência, consumo de energia e disponibilidade, delegando tarefas intensivas para infraestruturas robustas.

Otimização DRL

Aprendizado por Reforço Profundo (DRL) formula o offloading como um Processo de Decisão de Markov (MDP). Frameworks Multi-Agente (MARL) permitem execução descentralizada.

Aprendizado por Reforço Profundo

04



O Ambiente: Redes Ad Hoc Veiculares (VANETs) servem como o ambiente dinâmico para agentes DRL.

Frameworks DRL modelam ambientes veiculares como Processos de Decisão de Markov (MDPs) para maximizar desempenho minimizando latência e energia.

Estados (S)

O framework MDP define estados que capturam condições de canal em tempo real, atributos da tarefa e disponibilidade de recursos na rede.

Ações (A)

O agente determina ações ótimas, especificamente selecionando o servidor apropriado (Local, Borda, Nuvem) e frequência computacional.

Recompensas (R)

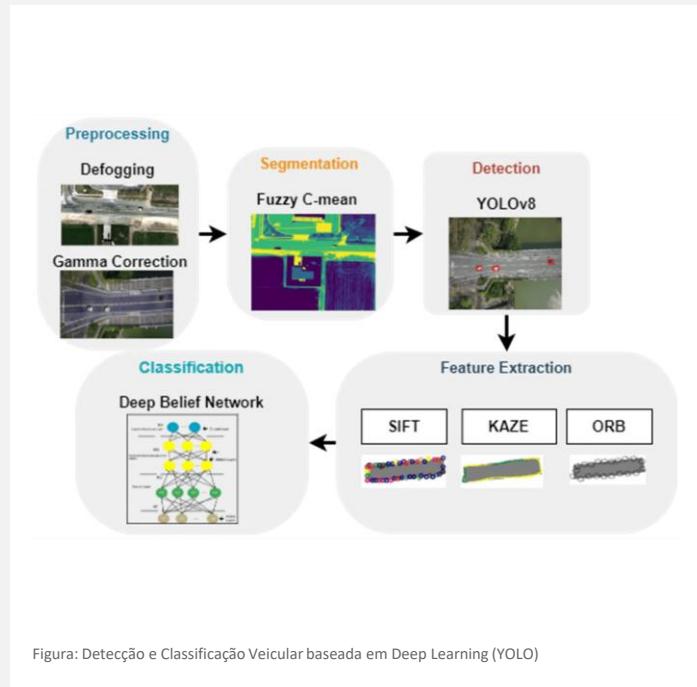
A função de recompensa é projetada para ser inversamente proporcional à latência e consumo de energia, guiando o agente para a eficiência.

Algoritmos

Algoritmos Deep Q-Network (DQN) são aplicados para espaços de ação discretos, enquanto frameworks Multi-Agente lidam com execução descentralizada.

Integrando VC com DRL

05



A arquitetura proposta combina Classificação Veicular de Granularidade Fina com offloading inteligente para aumentar a confiabilidade do ALPR.

- **Arquitetura DRL:** Selecionada com base na complexidade do ambiente e escalabilidade para gerenciar redes veiculares dinâmicas.
- **Distribuição Dinâmica:** Tarefas de processamento são distribuídas dinamicamente entre veículos e Roadside Units (RSUs) para minimizar latência.
- **Frameworks MARL:** Utiliza Aprendizado por Reforço Multi-Agente com Treinamento Centralizado e Execução Descentralizada (CTDE).
- **Otimização de Recursos:** Integração da Teoria dos Jogos com MARL para lidar efetivamente com a contenção de recursos multiusuário.

Classificação Veicular Fina

A integração FGVC fornece identificação validada cruzada para fortalecer a precisão do ALPR em condições adversas.

Modelos e Arquitetura

- Modelos Deep Learning: ViT b16, ResNet-34, EfficientNetV2 e MobileNetV3 utilizando transfer learning.
- Preparação de Dados: Dataset Rodosol-ALPR com Protocolo p2 (Oversampling) para equilibrar representação de classes.
- Detecção: YOLOv10 empregado para detecção e recorte preciso de veículos.

Estratégias de Refinamento

- Redução de Classes (Estática): Agrupa fabricantes menos frequentes em uma categoria genérica "Outros" para melhorar eficiência.
- Predição Seletiva (Online): Rejeita inferências quando a confiança cai abaixo de um limiar pré-definido.
- Objetivo: Mitigar falsos positivos e manter alta confiabilidade em tempo real.



Métricas de Desempenho FGVC

07

Estratégias de Redução de Classes
superam significativamente as
arquiteturas de referência na
identificação veicular.

Melhoria

+8.0%

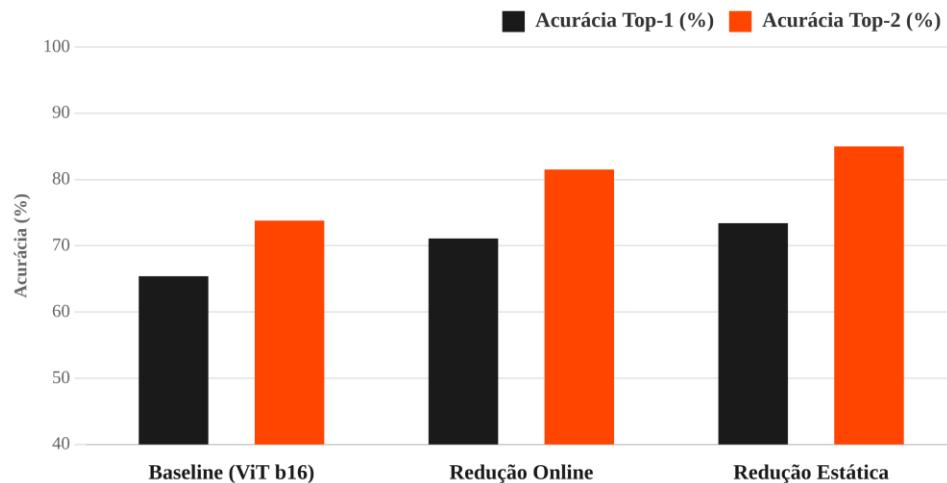
Ganho de Acurácia Top-1 com Redução de Classes Estática sobre Baseline.

Predição Seletiva

90.2%

Acurácia alcançada com limiar de confiança de 0.5 (taxa de rejeição de 44.7%).

Comparação de Acurácia de Classificação

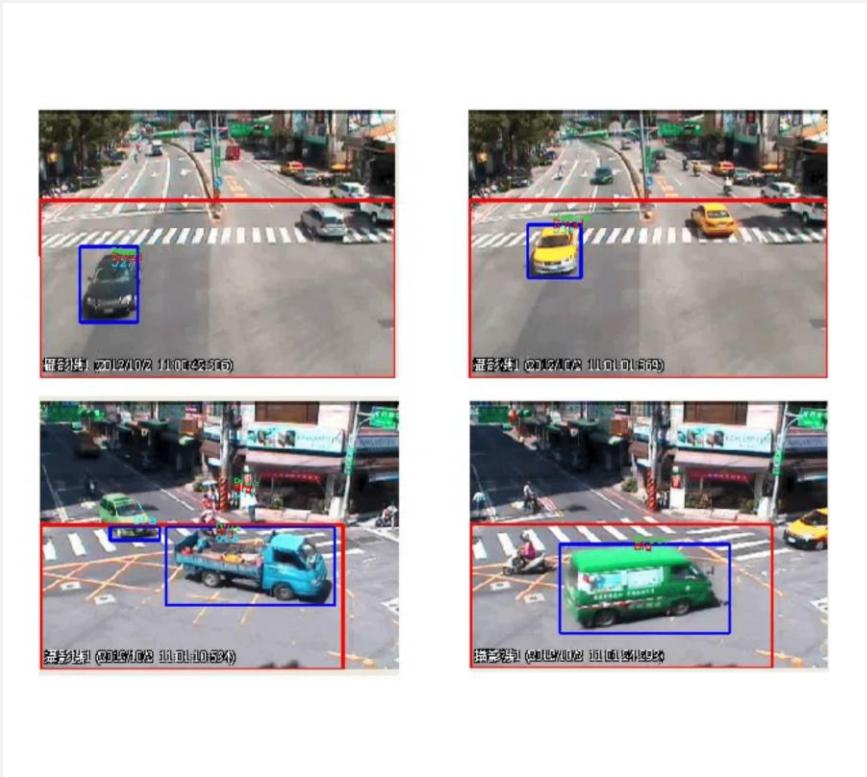


Análise da Matriz de Confusão

Redução significativa de falsos positivos entre marcas de veículos similares confirmada pela análise da matriz.

A análise visual confirma que o retreinamento melhora a dispersão diagonal, concentrando as previsões e reduzindo a confusão entre marcas em comparação com o baseline.

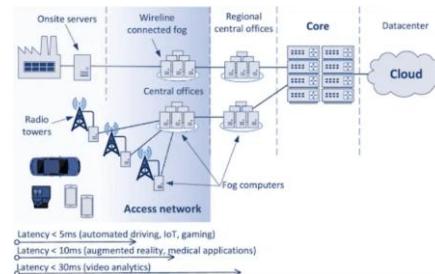
- **Dispersão Baseline:** Matriz inicial mostra erros significativos fora da diagonal.
- **Redução de Classes:** Concentra previsões ao longo da diagonal, melhorando a acurácia.
- **Predição Seletiva:** Equilibra precisão e taxa de rejeição para disponibilidade ótima.
- **Trade-off Crítico:** Limiar de confiança de 0.5 atinge 90.2% de acurácia com 44.7% de rejeição.



Topologias VEC e Offloading

Arquiteturas MEC hierárquicas fornecem escalabilidade superior e suporte à mobilidade em comparação com modelos centralizados.

Esquemas avançados de offloading baseados em Aprendizado por Reforço Profundo (ex: MADDPG) distribuem tarefas complexas entre camadas Local, Borda e Nuvem para otimizar latência e energia.



Topologia	Latência	Suporte à Mobilidade	Escalabilidade	Complexidade de Controle
MEC Centralizado	Baixa (Alta Carga)	Médio	Baixa	Baixa
MEC Distribuído	Muito Baixa	Alto	Alta	Média
ÓTIMO	MEC Hierárquico	Variável	Alto	Alta
MEC Ad-hoc	Muito Baixa	Muito Alto	Média	Muito Baixa

Autenticação Baseada em Identidade

IBA elimina a sobrecarga da infraestrutura PKI enquanto garante privacidade através de comunicações pseudônimas.

Autenticação de Fonte

Verifica a legitimidade da entidade e garante a integridade da mensagem sem gerenciamento pesado de certificados.

Preservação de Privacidade

Utiliza pseudônimos para proteger a identidade do usuário durante trocas V2V e V2I.

Rastreabilidade

Permite que uma Autoridade Confiável (TA) revogue o anonimato e identifique atores maliciosos quando necessário.

Não-Repúdio

Impede que entidades neguem a transmissão de mensagens, garantindo responsabilidade.



Sistemas ALPR atuando como nós de verificação na infraestrutura de segurança
Camera/ DVR on police car

Direções Futuras

11

Sistemas VANET de próxima geração integrarão offloading hierárquico, validação cruzada e adaptação rápida por meta-learning.

01

Offloading Colaborativo

Implementação de particionamento de redes neurais para transmitir apenas vetores de características. Otimizado via algoritmos MARL (Multi-Agent) com técnicas CTDE (Treinamento Centralizado com Execução Descentralizada) para reduzir uso de largura de banda.

02

Detecção Validada Cruzada

Validação de dados antes da transmissão para mitigar ataques Sybil. Uso de confirmação visual confiável para isolar simulações de identidade falsa.

03

Adaptação por Meta-Learning

Habilitar agentes para generalizar rapidamente para novos ambientes (ex: centros urbanos congestionados) inferindo modelos vizinhos para acelerar convergência de políticas.



Sistemas de transporte multimodais complexos exigindo inteligência adaptativa

Conclusão

12

A convergência de Visão Computacional Avançada e VEC fornece a base para o transporte autônomo seguro.

Identificação de Alta Precisão

Integração FGVC com ALPR fornece identificação validada cruzada com >90% de acurácia, mitigando erros em cenários adversos.

Infraestrutura Escalável

Arquiteturas VEC hierárquicas demonstram escalabilidade superior e suporte à mobilidade em comparação com modelos centralizados.

Otimização Dinâmica de Tarefas

Frameworks de offloading baseados em DRL (MARL com CTDE) gerenciam efetivamente a alocação dinâmica de tarefas na rede.

Comunicação Segura

Autenticação Baseada em Identidade (IBA) garante comunicações V2V/V2I eficientes e legítimas sem sobrecarga de PKI.

